Houston, tenemos un Q-Valor

Aprendizaje por refuerzo Lunar con DQN

Ivo Raimondi
Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla
Sevilla, España
ivorai@alum.us.es HMF2475

Miguel Romero Mateos
Dpto. Ciencias de la Computación e Inteligencia Artificial
Universidad de Sevilla
Sevilla, España
migrommat@alum.us.es KPH6911

***Resumen*—Este trabajo presenta una implementación del algoritmo Deep Q-Network (DQN) para resolver el entorno LunarLander de Gymnasium. El objetivo principal fue entrenar un agente capaz de aterrizar con éxito una nave lunar al menos en un 30% de los episodios, utilizando técnicas modernas de aprendizaje por refuerzo profundo. Se realizaron múltiples experimentos variando hiperparámetros como tamaño de red, tasa de aprendizaje y frecuencia de actualización de la red objetivo. Los resultados muestran que, con una arquitectura adecuada y una política de entrenamiento bien afinada, el agente puede alcanzar tasas de éxito superiores al 90%. Se discuten los desafíos encontrados y se proponen modelos capaces de completar el problema.**

***Palabras clave*—Aprendizaje por refuerzo, Deep Q-Network, Q-Learning, Optimizador, PyTorch, LunarLander, Gymnasium, redes neuronales, inteligencia artificial, experiencia, acción, estado, recompensa.**

ÍNDICE GENERAL

I. Introducción

El aprendizaje por refuerzo ha demostrado ser eficaz a la hora de resolver problemas complejos donde no se puede disponer de una supervisión continua del usuario, tales como videojuegos, robótica o sistemas de control autónomo. En relación a esto último, el proyecto LunarLander, desarrollado por OpenAI y actualmente mantenido por la fundación Farama [1], ejemplifica perfectamente el sistema de aprendizaje por refuerzo, resaltando su importancia en el día de hoy.

Este entorno simula la tarea de aterrizar un módulo lunar entre dos puntos marcados, enfrentando al agente a un terreno variable y condiciones iniciales aleatorias. El presente trabajo se centra en la implementación de una solución basada en aprendizaje por refuerzo para resolver el entorno de LunarLander, empleando una red neuronal de tipo feedforward.

El objetivo principal: desarrollar un modelo capaz de resolver con éxito el entorno en al menos un 30% de los episodios, utilizando para ello un algoritmo de Deep Q-Network (DQN). Para abordar esto, se ha optado por la utilización del lenguaje de programación Python y las bibliotecas especializadas PyTorch y Gymnasium, que ofrecen un conjunto de herramientas para el diseño, entrenamiento y evaluación de modelos de redes neuronales y entornos de aprendizaje por refuerzo [2].

Este documento se estructura de la siguiente manera: en la siguiente sección se describe en detalle el entorno LunarLander y sus componentes fundamentales; posteriormente se aborda la metodología empleada, detallando el algoritmo seleccionado y su implementación; a continuación se presentan los resultados experimentales y su análisis; y finalmente, se exponen las conclusiones extraídas del trabajo, así como posibles líneas futuras de mejora.

II. Algoritmos Implementados

El algoritmo *Deep Q-Network* (DQN) es una extensión del método clásico de *Q-learning* que permite aplicar aprendizaje por refuerzo a entornos con espacios de estados grandes o continuos, donde almacenar una tabla de valores Q para cada posible combinación de estado y acción se vuelve inviable [3, 7]. En lugar de una tabla explícita, DQN utiliza una **red neuronal profunda** que aproxima la función de valor de acción $Q(s, a)$, estimando para cada par estado-acción el valor esperado de la recompensa acumulada futura.

A. Fundamentos teóricos

La idea central de Q-learning es iterar sobre la llamada *ecuación de Bellman*, que define el valor óptimo de una acción como la recompensa inmediata más el valor descontado de la mejor acción futura [4]. En DQN, esta ecuación se convierte en el objetivo de entrenamiento para una red neuronal parametrizada por θ [9]. La función de pérdida a minimizar durante el entrenamiento se define como:

$$L(\theta) = E\left[\left(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta)\right)^2\right] \quad (1)$$

Donde:

- $Q(s, a; \theta)$: valor estimado por la red neuronal principal.
- $Q(s', a'; \theta^-)$: valor estimado por la red objetivo (una copia congelada).
- $\gamma \in [0, 1]$: factor de descuento para recompensas futuras.
- r: recompensa inmediata tras realizar la acción a en el estado s.
- s': nuevo estado alcanzado.

B. Arquitectura del sistema

El algoritmo DQN implementa tres componentes clave que lo distinguen del Q-learning tradicional:

- **Red Q principal** ($Q(s, a; \theta)$): red neuronal entrenada para aproximar los valores Q actuales.
- **Red objetivo** ($Q(s', a'; \theta^-)$): red congelada que proporciona valores estables como objetivo durante la optimización. Se sincroniza con la red principal cada ciertos pasos.
- **Memoria de experiencias (Replay Buffer)**: estructura de datos que almacena experiencias pasadas (s, a, r, s'). Durante el entrenamiento, se extraen muestras aleatorias para reducir la correlación temporal y mejorar la estabilidad [13].

C. Ciclo de aprendizaje

Cada iteración del entrenamiento DQN consta de los siguientes pasos:

1) **Selección de acción**: el agente observa el estado actual s y decide una acción a usando una política ϵ-greedy, que combina exploración aleatoria con explotación del conocimiento actual.
2) **Interacción con el entorno**: se obtiene la recompensa r, el nuevo estado s', y si el episodio ha terminado.
3) **Almacenamiento de experiencia**: se guarda la experiencia (s, a, r, s') en la memoria.
4) **Actualización del modelo**: se extrae un minibatch de experiencias para calcular los valores Q actuales y objetivo. Se calcula la pérdida y se actualizan los pesos de la red principal mediante descenso de gradiente.
5) **Actualización de la red objetivo**: cada N episodios, se copian los pesos de la red principal a la red objetivo: $\theta^- \leftarrow \theta$.

Este proceso implementado en nuestro código puede expresarse en el siguiente pseudocódigo:

Algorithm 1: Algoritmo de entrenamiento Deep Q-Network (DQN)

Data: Estado inicial s, redes `q_network` y `target_network`, `replay_buffer`, parámetros `epsilon`, `epsilon_decay`, `epsilon_min`, `replays_per_episode`, `target_network_update_freq`

for *episodio de* 1 *hasta* `episodes` **do**
- Reiniciar entorno y obtener estado inicial s;
- **while** *episodio no terminado y pasos <* `max_steps` **do**
  - Con probabilidad `epsilon`, seleccionar acción aleatoria;
  - En caso contrario, seleccionar acción con mayor valor Q según `q_network`;
  - Ejecutar acción, obtener recompensa r, siguiente estado s' y señal `done`;
  - Almacenar experiencia $(s, a, r, s', \texttt{done})$ en `replay_buffer`;
  - $s \leftarrow s'$;
- **end**
- **if** `replay_buffer` *tiene al menos* `batch_size` *muestras* **then**
  - **for** $i = 1$ *hasta* `replays_per_episode` **do**
    - Muestrear minibatch aleatorio de tamaño `batch_size`;
    - Calcular Q_{actual} desde `q_network` y Q_{objetivo} desde `target_network`;
    - Minimizar la pérdida entre ambos usando descenso por gradiente;
  - **end**
- **end**
- **if** *episodio* mod `target_network_update_freq` $== 0$ **then**
  - Copiar pesos de `q_network` a `target_network`;
- **end**
- Actualizar `epsilon = max(epsilon_min, epsilon * epsilon_decay);`

end

D. Hiperparámetros relevantes

El rendimiento del algoritmo depende de varios hiperparámetros clave:

- γ: factor de descuento (típicamente entre 0.95 y 0.99).
- α: tasa de aprendizaje del optimizador (en este trabajo se usó Adam).
- ϵ: tasa de exploración inicial, que se reduce gradualmente hasta un mínimo ϵ_{min}.
- Tamaño del minibatch.
- Frecuencia de actualización de la red objetivo.
- Capacidad del *replay buffer*.

E. Decisiones de diseño:

Durante la implementación se tomaron diversas decisiones técnicas y de diseño orientadas a optimizar el rendimiento y la eficiencia del modelo:

- **Uso de PyTorch**: se optó por la librería PyTorch por su flexibilidad y control explícito del flujo de datos y del entrenamiento, lo que facilita la depuración y comprensión del proceso de aprendizaje en profundidad [2, 5, 19].
- **Definición del hardware**: se incluyó una asignación automática del dispositivo (cuda o CPU), permitiendo aprovechar la aceleración por GPU en sistemas compatibles, mejorando significativamente los tiempos de entrenamiento.
- **Arquitectura de la Red Neuronal**: se diseñó una red *feedforward* con dos capas ocultas de igual tamaño, activadas mediante la función ReLU, ampliamente utilizada por su rendimiento computacional y capacidad para mitigar el problema de desvanecimiento de gradiente.
- **Optimizador Adam**: se seleccionó el algoritmo Adam como optimizador, debido a su capacidad de adaptar dinámicamente la tasa de aprendizaje por parámetro, lo que facilita una convergencia más rápida y estable.
- **Visualización y Análisis**: se integraron herramientas como matplotlib y pandas para registrar métricas clave y generar gráficos representativos del progreso durante el entrenamiento (score, pérdida, duración de episodios, valores Q medios, etc.), facilitando el análisis cuantitativo de resultados.

F. Dificultades encontradas:

La implementación del algoritmo implicó resolver diversos retos técnicos, principalmente relacionados con el tratamiento de datos y la compatibilidad entre estructuras:

- **Integración de dispositivos**: adaptar el código al uso de GPU requirió una conversión de los datos a tensores PyTorch compatibles, utilizando NumPy. En caso de no haberse convertido correctamente, hubiesen surgido errores al transferir datos al dispositivo y el proyecto no se podría haber implementado.
- **Uso del *unsqueeze***: al predecir acciones con la red neuronal, fue necesario insertar una dimensión adicional al tensor de estado para simular un batch de tamaño uno. Este detalle fue crítico para mantener la compatibilidad con las operaciones de PyTorch.
- **Diseño de la función *train***: fue esencial estructurar adecuadamente el flujo del entrenamiento, determinando cuándo actualizar la red objetivo, cuándo almacenar experiencias y cómo aplicar correctamente la función de pérdida y el optimizador.
- **Visualización de los resultados**: la integración de gráficos con matplotlib y pandas implicó coordinar la recopilación de datos por episodio, implementar promedios móviles y asegurar una representación clara y coherente de los indicadores de rendimiento.

III. Experimentación

A continuación, se detallan todas las pruebas realizadas sobre nuestro algoritmo, explorando distintos ajustes en los hiperparámetros más relevantes para afinar nuestros modelos. Entre ellos se incluyen:

- **max_steps**: número máximo de pasos antes de finalizar un episodio.
- **hidden_size**: cantidad de neuronas en la capa oculta de las redes neuronales DQN. En nuestro caso siempre que hablemos de esto será de 2 capas del mismo tamaño.
- **replays_per_episode**: número de veces que se actualiza la red neuronal durante un solo episodio.
- **episodes**: cantidad total de episodios o simulaciones completas que el agente ejecuta durante el proceso de entrenamiento.
- **learning_rate**: tasa de aprendizaje, que determina el tamaño del paso durante la minimización de la función de pérdida.
- **batch_size**: número de experiencias (transiciones estado-acción-recompensa) utilizadas en cada iteración de entrenamiento.
- **memory_size**: capacidad máxima de la memoria de repetición (ReplayBuffer), donde se almacenan experiencias pasadas para el aprendizaje.
- **target_network_update_freq**: frecuencia, en número de episodios, con la que se actualizan los pesos de la red objetivo (target network) para igualarlos a los de la red principal (Q-network).

Ajustando adecuadamente estos hiperparámetros, podemos obtener un modelo más eficiente y efectivo. Existen varios métodos para optimizar estos valores, como la búsqueda en rejilla (*grid search*); sin embargo, dado que esta técnica es más adecuada cuando se trabaja con espacios discretos y que en nuestro caso sería computacionalmente costosa —ya que no contamos con recursos de alto rendimiento—, optamos por una estrategia más práctica: realizar pruebas aleatorias, pero fundamentadas en criterios razonables y experiencia previa adquirida durante el curso e investigación.

Para no saturar nuestros equipos personales, realizamos las pruebas utilizando la plataforma Google Colab. Inicialmente, los experimentos fueron nombrados como *Colab X* (donde X es el número de prueba). Posteriormente, seleccionamos cinco modelos destacados, a los que asignamos nombres descriptivos según su comportamiento y desempeño.

Antes de analizar cada uno, debemos establecer cómo definimos si un episodio fue exitoso. El entorno de LunarLander proporciona recompensas intermedias a lo largo del episodio que dependen de múltiples factores:

- **Penalizaciones**: alejarse de la plataforma de aterrizaje, moverse demasiado rápido, inclinarse excesivamente, usar los motores (especialmente el principal), o estrellarse.
- **Recompensas**: mantenerse cerca del centro, aterrizar con suavidad, usar poca propulsión, apoyar las patas sin colisión y estabilizar la nave.

Considerando estas señales, definimos que un episodio exitoso es aquel cuya recompensa total es mayor o igual a **100 puntos**, ya que esto implica un aterrizaje controlado, eficiente y seguro, sin abusar de los motores ni desviarse significativamente de la plataforma.

A continuación, se presenta el análisis de los cinco modelos seleccionados, detallando sus configuraciones, el progreso observado durante el entrenamiento, los resultados obtenidos y una interpretación del comportamiento aprendido por el agente en cada caso.

A. *Colab 1* - *DopeyLander*

Estos son los hiperparámetros usados en este modelo:

```
#Los parametros más importantes son los marcados con un comentario
agent = DQNAgent(lunar,replays_per_episode=1000,epsilon=1.0, epsilon_decay=0.995, epsilon_min=0.01,
                 episodes=3000, #Episodios de entrenamiento
                 hidden_size=256 ,#Tamaño de la capa oculta
                 gamma=0.99, # Factor de descuento
                 learning_rate=0.001, #Tasa de aprendizaje
                 batch_size=64, #Tamaño minibatch
                 memory_size=10000, #Tamaño replay buffer
                 target_network_update_freq=15 #Actualizacion de la red objetivo
                 )
# agent.load_model("modelos/modelo_DQN.h5") <- si se quiere seguir entrenando el modelo anteriormente guardado
agent.train(nombre_archivo="modelos/modelo_DQN", save_graphs=True, save_every_50=True)
```

Fig. 1. Estos fueron los hiperparametros configurados para Colab 1

Este fue el primer experimento, y funcionó como línea base. Se utilizó una red con una capa oculta muy grande (256 neuronas en ambas capas ocultas), una tasa de aprendizaje alta y una enorme cantidad de actualizaciones por episodio (1000 replays).

A continuación, se muestra una imagen del entorno de trabajo en Google Colab durante el entrenamiento:

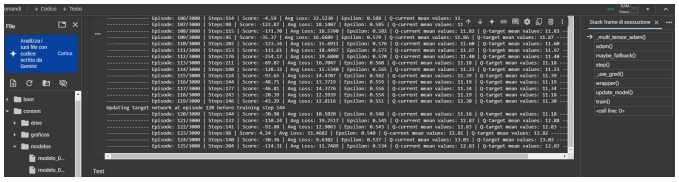

Fig. 2. Progreso durante el entrenamiento - Colab 1

Aunque el agente aprendió que debía encender el motor principal al principio para no caer directamente, nunca logró estabilizarse ni aterrizar correctamente. El entrenamiento fue extremadamente costoso (3000 episodios con 1000 replays cada uno), y no se observaron mejoras significativas a medida que disminuía el valor de epsilon.

Los siguientes gráficos muestran el rendimiento del modelo durante su entrenamiento:

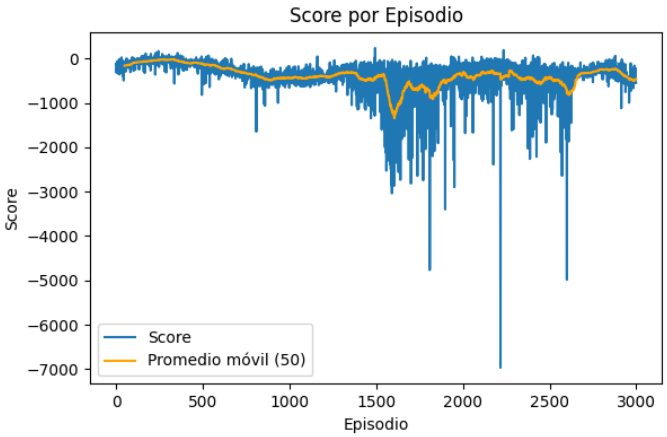

Fig. 3. Recompensa total con promedio móvil de los episodios - Colab 1

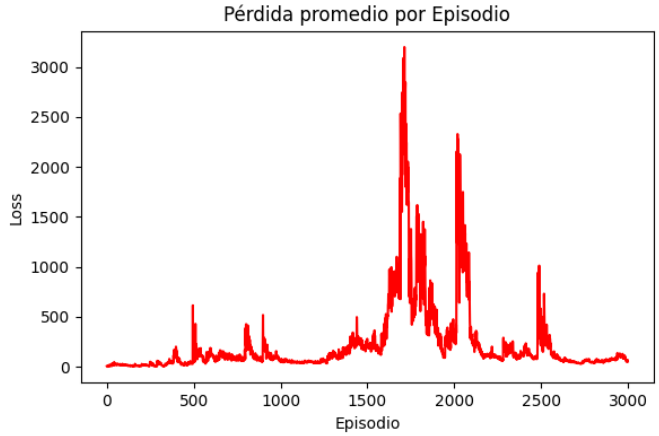

Fig. 4. Pérdida promedio por episodio - Colab 1

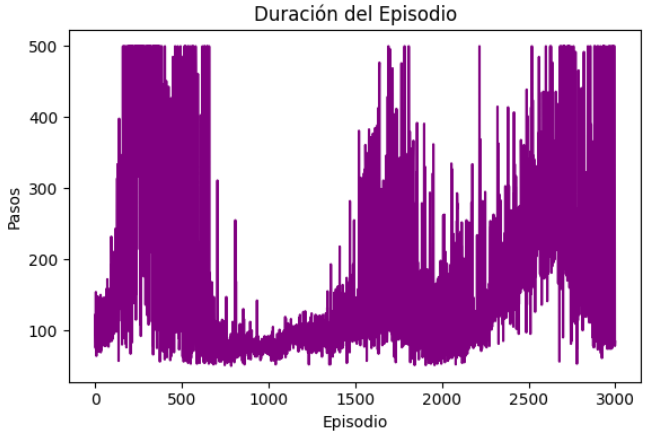

Fig. 5. Duración de los episodios - Colab 1

Como puede observarse, el modelo nunca logró especializarse. Mantuvo recompensas bajas durante todo el entrenamiento, su pérdida promedio fue constantemente elevada y los episodios caóticos.

La siguiente figura muestra la tasa de acierto una vez finalizado el entrenamiento usando $\epsilon = 0.0$, es decir, sin exploración:

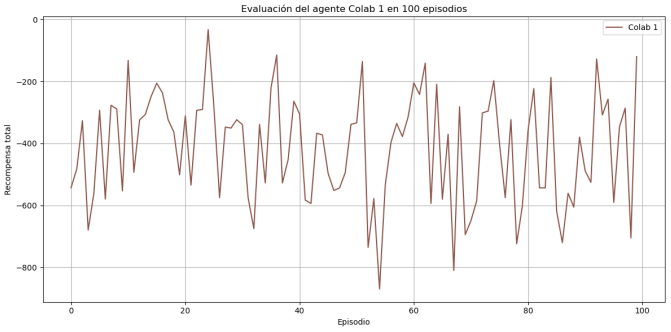

Fig. 6. Tasa de acierto de Colab 1 con el modelo ya entrenado - Colab 1

El resultado fue un rendimiento nulo, con una tasa de acierto del **0.00%**.

*B. **Colab 2** - First Lander*

Estos son los hiperparámetros usados en este modelo:

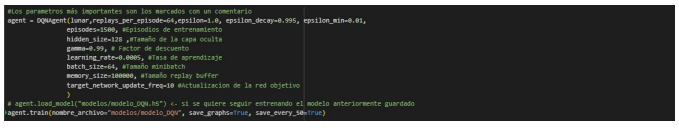

```
#Los parametros más importantes son los marcados con un comentario
agent = DQNAgent(lunar,replays_per_episode=64,epsilon=1.0, epsilon_decay=0.995, epsilon_min=0.01,
                 episodes=1500, #Episodios de entrenamiento
                 hidden_size=128 ,#Tamaño de la capa oculta
                 gamma=0.99, # Factor de descuento
                 learning_rate=0.0005, #Tasa de aprendizaje
                 batch_size=64, #Tamaño minibatch
                 memory_size=100000, #Tamaño replay buffer
                 target_network_update_freq=10 #Actualizacion de la red objetivo
                 )
# agent.load_model("modelos/modelo_DQN.h5") <- si se quiere seguir entrenando el modelo anteriormente guardado
agent.train(nombre_archivo="modelos/modelo_DQN", save_graphs=True, save_every_50=True)
```

Fig. 7. Hiperparámetros usados en Colab 2

Este modelo representó una mejora significativa respecto al anterior. Se redujo el tamaño de la red a 128 neuronas en ambas capas ocultas, se utilizaron solo 64 replays por episodio y la tasa de aprendizaje se disminuyó a 0.0005. Esto favoreció la estabilidad del entrenamiento y permitió un aprendizaje más fino.

Podemos ver un poco de cómo avanzó su aprendizaje:

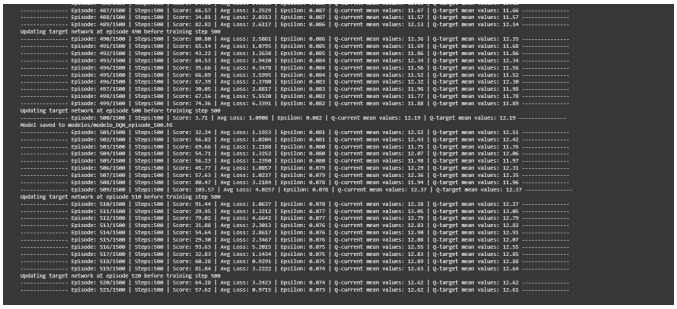

Fig. 8. Progreso durante el entrenamiento - Colab 2

El agente aprendió a dejarse caer al inicio y luego usar el propulsor principal para corregir su trayectoria, estabilizándose con los motores laterales y logrando aterrizajes suaves. El entrenamiento se realizó en 1500 episodios, lo que permitió un buen aprovechamiento de la fase de exploración.

Con los siguientes gráficos se puede observar cómo fue evolucionando el entrenamiento:

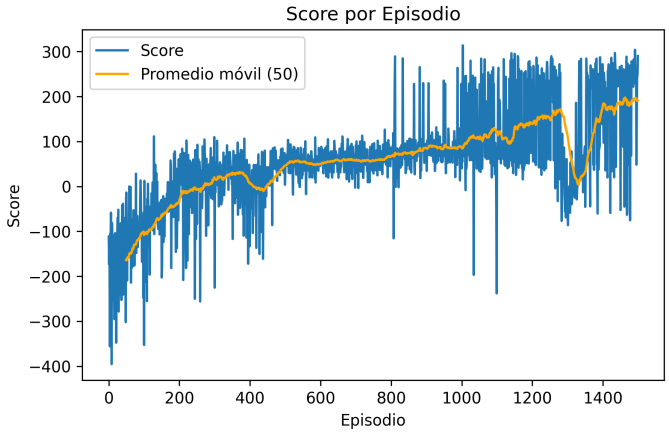

Fig. 9. Recompensa total con promedio móvil - Colab 2

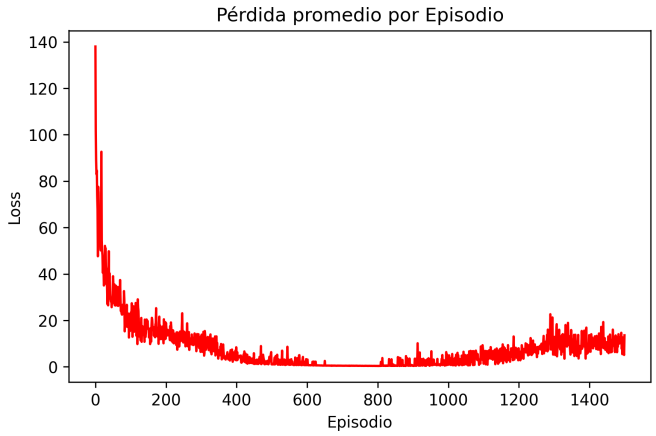

Fig. 10. Pérdida promedio por episodio - Colab 2

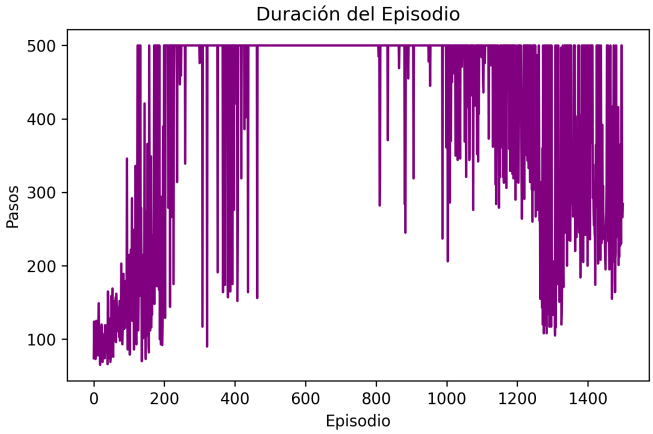

Fig. 11. Duración de los episodios - Colab 2

La evolución de la recompensa muestra una clara tendencia positiva, con una pérdida que se estabiliza gradualmente y una duración de episodios que se ajusta conforme mejora la política aprendida. Estos indicadores reflejan una buena capacidad de generalización y eficiencia en el aprendizaje.

Un aspecto llamativo es la caída abrupta en la recompensa alrededor del episodio 1350 (entre otras que tiene). Esto podría explicarse por el uso de experiencias poco representativas o negativas almacenadas en el replay buffer, que afectaron momentáneamente el proceso de actualización del modelo. Este comportamiento resalta que un mayor número de episodios no garantiza por sí solo un mejor desempeño, especialmente si las muestras recientes no son de buena calidad.

Veremos ahora cómo evolucionó la tasa de acierto del modelo entrenado:

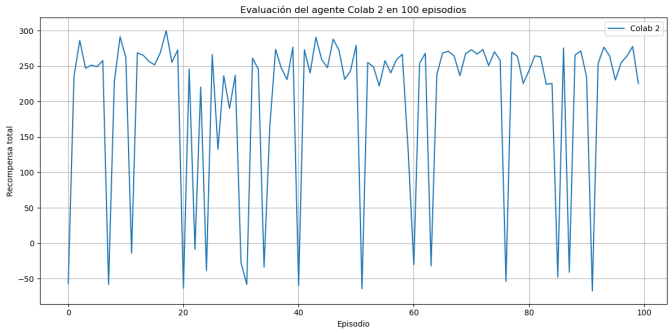

Fig. 12. Tasa de acierto del modelo ya entrenado - Colab 2

Este modelo logró una tasa de acierto del **81.00%**, posicionándose como uno de los más estables y eficientes del conjunto.

*C. **Colab 3** - NO-Lander*

Estos son los hiperparámetros usados en este modelo:

```
#Los parametros más importantes son los marcados con un comentario
agent = DQNAgent(lunar,replays_per_episode=64,epsilon=1.0, epsilon_decay=0.995, epsilon_min=0.01,
                 episodes=1500, #Episodios de entrenamiento
                 hidden_size=128 ,#Tamaño de la capa oculta
                 gamma=0.99, # Factor de descuento
                 learning_rate=0.0005, #Tasa de aprendizaje
                 batch_size=128, #Tamaño minibatch
                 memory_size=100000, #Tamaño replay buffer
                 target_network_update_freq=10 #Actualizacion de la red objetivo
                 )
# agent.load_model("modelos/modelo_DQN.h5") <- si se quiere seguir entrenando el modelo anteriormente guardado
agent.train(nombre_archivo="modelos/modelo_DQN", save_graphs=True, save_every_50=True)
```

Fig. 13. Hiperparámetros usados en Colab 3

Este modelo mostró un comportamiento peculiar. El agente flotaba durante largos períodos y evitaba aterrizar, por mantener el motor principal encendido demasiado tiempo. La mayoría de los episodios se truncaban al alcanzar el límite de pasos (500), priorizando evitar castigos antes que buscar la recompensa de aterrizaje.

A continuación, se puede observar el progreso general del modelo durante su entrenamiento:

```
Episodio 1245 | Steps: 500 | Score:   80.47 | Avg Loss: 0.1603 | Epsilon: 0.010 | Q-current mean values: 17.04 | Q-target mean values: 17.04
Episodio 1246 | Steps: 500 | Score:   32.28 | Avg Loss: 0.1607 | Epsilon: 0.010 | Q-current mean values: 17.33 | Q-target mean values: 17.33
Episodio 1247 | Steps: 500 | Score:   37.80 | Avg Loss: 0.1624 | Epsilon: 0.010 | Q-current mean values: 16.96 | Q-target mean values: 16.96
Episodio 1248 | Steps: 500 | Score:  106.85 | Avg Loss: 0.1624 | Epsilon: 0.010 | Q-current mean values: 16.34 | Q-target mean values: 16.34
Episodio 1249 | Steps: 500 | Score:   32.13 | Avg Loss: 0.1576 | Epsilon: 0.010 | Q-current mean values: 16.46 | Q-target mean values: 16.46
Episodio 1250 | Steps: 500 | Score:   67.50 | Avg Loss: 0.1640 | Epsilon: 0.010 | Q-current mean values: 17.20 | Q-target mean values: 17.20
Episodio 1251 | Steps: 500 | Score:   92.94 | Avg Loss: 0.1751 | Epsilon: 0.010 | Q-current mean values: 17.21 | Q-target mean values: 17.21
Episodio 1252 | Steps: 500 | Score:   70.27 | Avg Loss: 0.1602 | Epsilon: 0.010 | Q-current mean values: 16.95 | Q-target mean values: 16.94
Episodio 1253 | Steps: 500 | Score:   37.94 | Avg Loss: 0.1511 | Epsilon: 0.010 | Q-current mean values: 16.28 | Q-target mean values: 16.29
Episodio 1254 | Steps: 500 | Score:   38.05 | Avg Loss: 0.1627 | Epsilon: 0.010 | Q-current mean values: 17.24 | Q-target mean values: 17.23
Episodio 1255 | Steps: 500 | Score:   51.45 | Avg Loss: 0.1591 | Epsilon: 0.010 | Q-current mean values: 17.11 | Q-target mean values: 17.11
Episodio 1256 | Steps: 500 | Score:   83.38 | Avg Loss: 0.1587 | Epsilon: 0.010 | Q-current mean values: 16.08 | Q-target mean values: 16.09
Episodio 1257 | Steps: 500 | Score:   74.79 | Avg Loss: 0.1548 | Epsilon: 0.010 | Q-current mean values: 16.79 | Q-target mean values: 16.79
Episodio 1258 | Steps: 500 | Score:   96.56 | Avg Loss: 0.1597 | Epsilon: 0.010 | Q-current mean values: 17.20 | Q-target mean values: 17.20
Episodio 1259 | Steps: 500 | Score:   70.25 | Avg Loss: 0.1644 | Epsilon: 0.010 | Q-current mean values: 17.37 | Q-target mean values: 17.37
Episodio 1260 | Steps: 500 | Score:   75.02 | Avg Loss: 0.1543 | Epsilon: 0.010 | Q-current mean values: 16.81 | Q-target mean values: 16.81
Episodio 1261 | Steps: 500 | Score:   53.83 | Avg Loss: 0.1572 | Epsilon: 0.010 | Q-current mean values: 17.09 | Q-target mean values: 17.09
Episodio 1262 | Steps: 500 | Score:   73.85 | Avg Loss: 0.1600 | Epsilon: 0.010 | Q-current mean values: 17.24 | Q-target mean values: 17.24
Episodio 1263 | Steps: 500 | Score:   92.79 | Avg Loss: 0.1551 | Epsilon: 0.010 | Q-current mean values: 17.19 | Q-target mean values: 17.19
Episodio 1264 | Steps: 500 | Score:   56.31 | Avg Loss: 0.1564 | Epsilon: 0.010 | Q-current mean values: 17.33 | Q-target mean values: 17.33
Episodio 1265 | Steps: 500 | Score:   91.36 | Avg Loss: 0.1523 | Epsilon: 0.010 | Q-current mean values: 16.38 | Q-target mean values: 16.38
Episodio 1266 | Steps: 500 | Score:   92.31 | Avg Loss: 0.1605 | Epsilon: 0.010 | Q-current mean values: 17.04 | Q-target mean values: 17.04
Episodio 1267 | Steps: 500 | Score:   76.92 | Avg Loss: 0.1575 | Epsilon: 0.010 | Q-current mean values: 17.24 | Q-target mean values: 17.24
Episodio 1268 | Steps: 500 | Score:   77.84 | Avg Loss: 0.1656 | Epsilon: 0.010 | Q-current mean values: 17.22 | Q-target mean values: 17.22
```

Fig. 14. Progreso durante el entrenamiento - Colab 3

A pesar de su política evasiva, el entrenamiento fue relativamente estable. Se utilizó un batch de tamaño mayor (128), lo que ralentizó el aprendizaje, pero permitió actualizaciones más suaves.

Los siguientes gráficos permiten analizar su entrenamiento con mayor detalle:

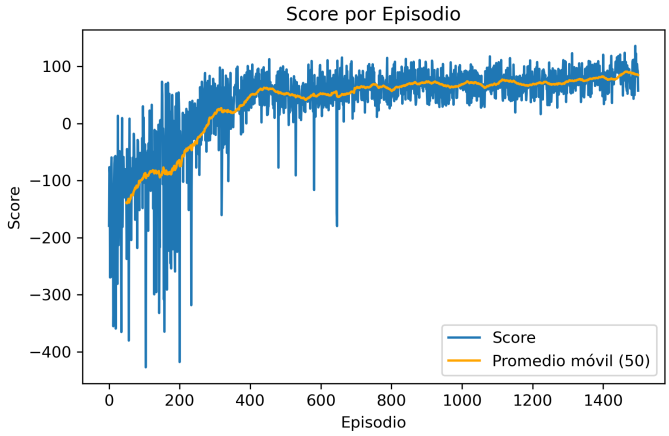

Fig. 15. Recompensa total con promedio móvil - Colab 3

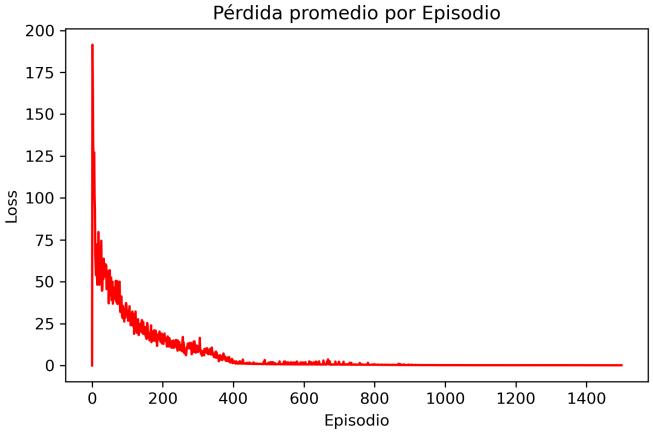

Fig. 16. Pérdida promedio por episodio - Colab 3

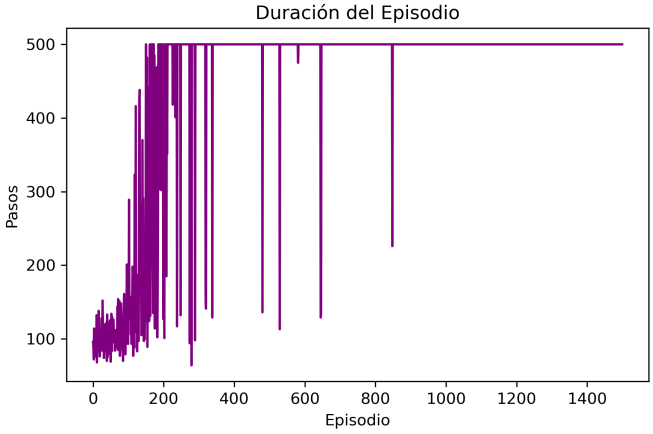

Fig. 17. Duración de los episodios - Colab 3

Aunque la recompensa y la pérdida muestran cierta mejora, el aumento sostenido en la duración de los episodios sugiere que el agente aprendió a evitar terminar la tarea, en lugar de completarla de forma óptima.

Finalizado el entrenamiento, se evaluó la política aprendida sin exploración:

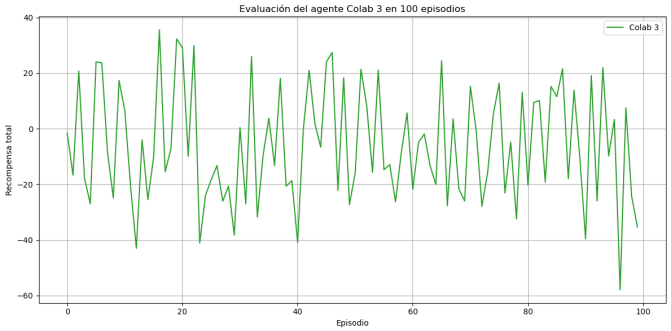

Fig. 18. Tasa de acierto del modelo ya entrenado - Colab 3

Este modelo no logró aterrizar correctamente en ninguna prueba final, obteniendo una tasa de acierto del **0.00%**.

*D. **Colab 4** - The King Lander*

Estos son los hiperparámetros usados en este modelo:

```
#Los parametros más importantes son los marcados con un comentario
agent = DQNAgent(lunar,replays_per_episode=32,epsilon=1.0, epsilon_decay=0.995, epsilon_min=0.01,
                 episodes=1500, #Episodios de entrenamiento
                 hidden_size=256 ,#Tamaño de la capa oculta
                 gamma=0.99, # Factor de descuento
                 learning_rate=0.0005, #Tasa de aprendizaje
                 batch_size=64, #Tamaño minibatch
                 memory_size=100000, #Tamaño replay buffer
                 target_network_update_freq=10 #Actualizacion de la red objetivo
                 )
# agent.load_model("modelos/modelo_DQN.h5") <- si se quiere seguir entrenando el modelo anteriormente guardado
agent.train(nombre_archivo="modelos/modelo_DQN", save_graphs=True, save_every_50=True)
```

Fig. 19. Hiperparámetros usados en Colab 4

Este fue el modelo con mejor desempeño general. Utilizó una red más profunda (256 neuronas en cada capa oculta), pero con una cantidad reducida de actualizaciones por episodio (32 replays), lo cual ayudó a prevenir el sobreajuste. La combinación de una tasa de aprendizaje moderada y una política de exploración bien balanceada permitió un aprendizaje rápido, estable y generalizable.

El progreso del modelo fue el siguiente:

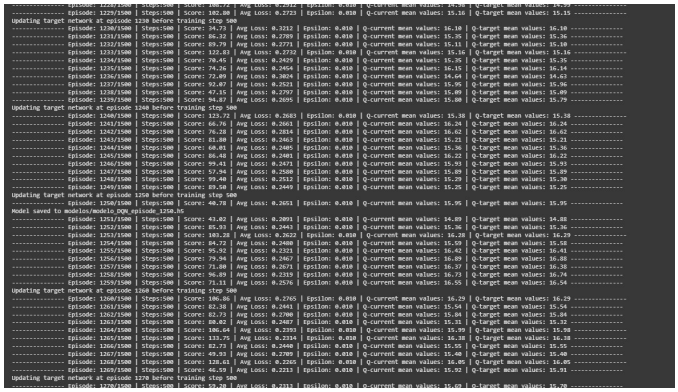

Fig. 20. Progreso durante el entrenamiento - Colab 4

Durante el entrenamiento, el agente fue capaz de ejecutar maniobras complejas desde estados iniciales desfavorables, logrando una mejora sostenida en el desempeño. Se observó una clara estabilidad y consistencia en los resultados obtenidos a lo largo de los episodios. Con los gráficos generados en la fase de entrenamiento, se puede observar lo siguiente:

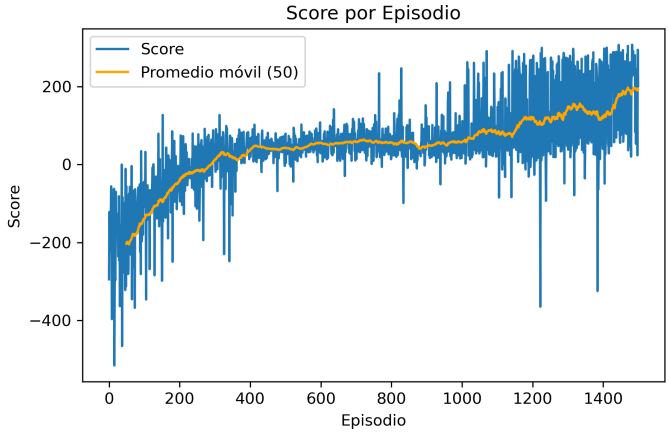

Fig. 21. Recompensa total con promedio móvil - Colab 4

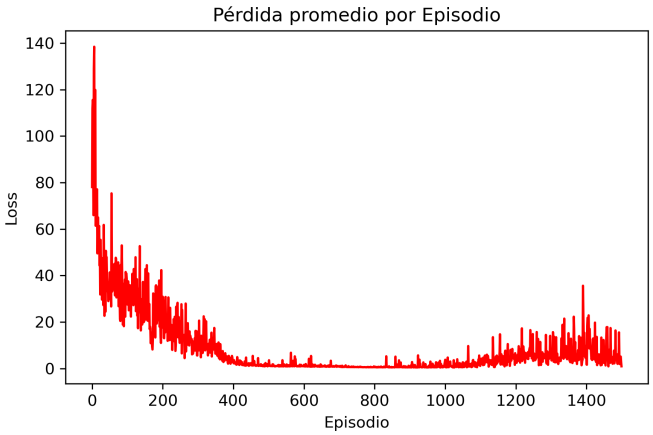

Fig. 22. Pérdida promedio por episodio - Colab 4

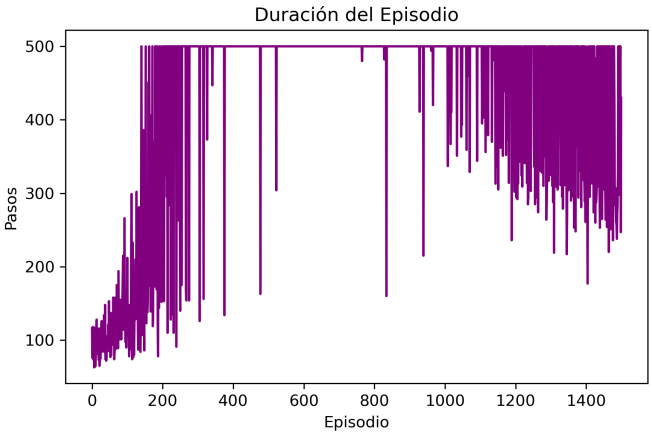

Fig. 23. Duración de los episodios - Colab 4

Los resultados muestran una recompensa creciente y sostenida con una variabilidad significativamente menor respecto a otros modelos. La pérdida disminuye de forma progresiva hasta estabilizarse, indicando que el modelo alcanza una convergencia adecuada. Además, la duración de los episodios se va acortando, lo que sugiere que el agente aprende a completar la tarea de manera más eficiente con el tiempo. Este comportamiento refleja una política bien afinada, capaz de generalizar correctamente a lo largo del entrenamiento.

En la fase de prueba (con $\epsilon = 0$) se obtuvo el siguiente rendimiento:

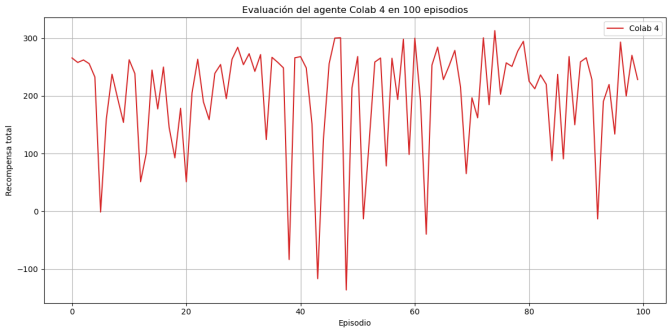

Fig. 24. Tasa de acierto del modelo ya entrenado - Colab 4

Con una tasa de acierto del **91.00%**, este modelo demostró ser el más eficiente y consistente entre todos los evaluados, validando así la combinación de arquitectura y parámetros elegidos.

*E. **Colab 5** - Cheaty Lander*

Estos son los hiperparámetros usados en este modelo:

```
#Los parametros más importantes son los marcados con un comentario
agent = DQNAgent(lunar,replays_per_episode=64,epsilon=1.0, epsilon_decay=0.995, epsilon_min=0.1,
                 episodes=2000, #Episodios de entrenamiento
                 hidden_size=64 ,#Tamaño de la capa oculta
                 gamma=0.99, # Factor de descuento
                 learning_rate=0.00005, #Tasa de aprendizaje
                 batch_size=64, #Tamaño minibatch
                 memory_size=100000, #Tamaño replay buffer
                 target_network_update_freq=20 #Actualizacion de la red objetivo
                 )
# agent.load_model("modelos/modelo_DQN.h5") <- si se quiere seguir entrenando el modelo anteriormente guardado
agent.train(nombre_archivo="modelos/modelo_DQN", save_graphs=True, save_every_50=True)
```

Fig. 25. Hiperparámetros usados en Colab 5

Este experimento intentó maximizar la estabilidad. Se usó una red muy liviana (64 neuronas en cada capa oculta), una tasa de aprendizaje extremadamente baja (0.00005), se limitaron los pasos por episodio a 300, se fijó un valor mínimo de epsilon más alto (0.1) y se acortó el máximo de pasos a 300.

Su progreso puede observarse en la siguiente figura:

```
------------ Episode: 936/2000 | Steps:300 | Score: 19.52 | Avg Loss: 1.9683 | Epsilon: 0.100 | Q-current mean values: 4.51 | Q-target mean values: 4.52 ------------
------------ Episode: 937/2000 | Steps:300 | Score: 14.83 | Avg Loss: 2.0640 | Epsilon: 0.100 | Q-current mean values: 4.66 | Q-target mean values: 4.66 ------------
------------ Episode: 938/2000 | Steps:300 | Score: 8.48 | Avg Loss: 1.8848 | Epsilon: 0.100 | Q-current mean values: 5.04 | Q-target mean values: 5.04 ------------
------------ Episode: 939/2000 | Steps:300 | Score: 27.75 | Avg Loss: 1.9333 | Epsilon: 0.100 | Q-current mean values: 4.82 | Q-target mean values: 4.82 ------------
updating target network at episode 940 before training step 300
------------ Episode: 940/2000 | Steps:300 | Score: 24.14 | Avg Loss: 2.1228 | Epsilon: 0.100 | Q-current mean values: 4.83 | Q-target mean values: 4.83 ------------
------------ Episode: 941/2000 | Steps:300 | Score: 22.39 | Avg Loss: 2.3628 | Epsilon: 0.100 | Q-current mean values: 5.03 | Q-target mean values: 5.03 ------------
------------ Episode: 942/2000 | Steps:300 | Score: 1.60 | Avg Loss: 2.4715 | Epsilon: 0.100 | Q-current mean values: 5.09 | Q-target mean values: 5.11 ------------
------------ Episode: 943/2000 | Steps:300 | Score: 22.06 | Avg Loss: 2.5833 | Epsilon: 0.100 | Q-current mean values: 4.92 | Q-target mean values: 4.94 ------------
------------ Episode: 944/2000 | Steps:300 | Score: 24.58 | Avg Loss: 2.5334 | Epsilon: 0.100 | Q-current mean values: 5.03 | Q-target mean values: 5.02 ------------
------------ Episode: 945/2000 | Steps:300 | Score: 63.01 | Avg Loss: 2.0426 | Epsilon: 0.100 | Q-current mean values: 5.21 | Q-target mean values: 5.21 ------------
------------ Episode: 946/2000 | Steps:300 | Score: 6.91 | Avg Loss: 2.4288 | Epsilon: 0.100 | Q-current mean values: 5.03 | Q-target mean values: 5.03 ------------
------------ Episode: 947/2000 | Steps:300 | Score: 45.74 | Avg Loss: 2.2600 | Epsilon: 0.100 | Q-current mean values: 5.18 | Q-target mean values: 5.18 ------------
------------ Episode: 948/2000 | Steps:300 | Score: 4.48 | Avg Loss: 2.0394 | Epsilon: 0.100 | Q-current mean values: 5.07 | Q-target mean values: 5.07 ------------
------------ Episode: 949/2000 | Steps:300 | Score: 49.78 | Avg Loss: 2.3055 | Epsilon: 0.100 | Q-current mean values: 5.10 | Q-target mean values: 5.11 ------------
------------ Episode: 950/2000 | Steps:300 | Score: 34.19 | Avg Loss: 2.0871 | Epsilon: 0.100 | Q-current mean values: 4.92 | Q-target mean values: 4.93 ------------
Model saved to modelos/modelo_DQN_episode_950.h5
------------ Episode: 951/2000 | Steps:300 | Score: -20.47 | Avg Loss: 2.0228 | Epsilon: 0.100 | Q-current mean values: 4.96 | Q-target mean values: 4.97 ------------
------------ Episode: 952/2000 | Steps:300 | Score: -11.33 | Avg Loss: 1.5430 | Epsilon: 0.100 | Q-current mean values: 5.09 | Q-target mean values: 5.11 ------------
------------ Episode: 953/2000 | Steps:300 | Score: 9.46 | Avg Loss: 2.1431 | Epsilon: 0.100 | Q-current mean values: 5.11 | Q-target mean values: 5.09 ------------
------------ Episode: 954/2000 | Steps:300 | Score: 45.77 | Avg Loss: 2.1783 | Epsilon: 0.100 | Q-current mean values: 5.06 | Q-target mean values: 5.05 ------------
------------ Episode: 955/2000 | Steps:300 | Score: 51.32 | Avg Loss: 1.9175 | Epsilon: 0.100 | Q-current mean values: 5.14 | Q-target mean values: 5.15 ------------
------------ Episode: 956/2000 | Steps:300 | Score: 14.78 | Avg Loss: 2.0135 | Epsilon: 0.100 | Q-current mean values: 4.85 | Q-target mean values: 4.86 ------------
------------ Episode: 957/2000 | Steps:300 | Score: 6.07 | Avg Loss: 1.9022 | Epsilon: 0.100 | Q-current mean values: 5.00 | Q-target mean values: 5.01 ------------
------------ Episode: 958/2000 | Steps:300 | Score: 35.23 | Avg Loss: 1.9165 | Epsilon: 0.100 | Q-current mean values: 5.24 | Q-target mean values: 5.24 ------------
------------ Episode: 959/2000 | Steps:300 | Score: 12.28 | Avg Loss: 2.0018 | Epsilon: 0.100 | Q-current mean values: 5.24 | Q-target mean values: 5.23 ------------
```

Fig. 26. Progreso durante el entrenamiento - Colab 5

El agente aprendió a estabilizarse en el aire, pero nunca llegó a aterrizar correctamente. La política aprendida fue demasiado conservadora y no incentivaba a tomar riesgos para completar la tarea.

Durante la fase de entrenamiento se generaron los siguientes gráficos:

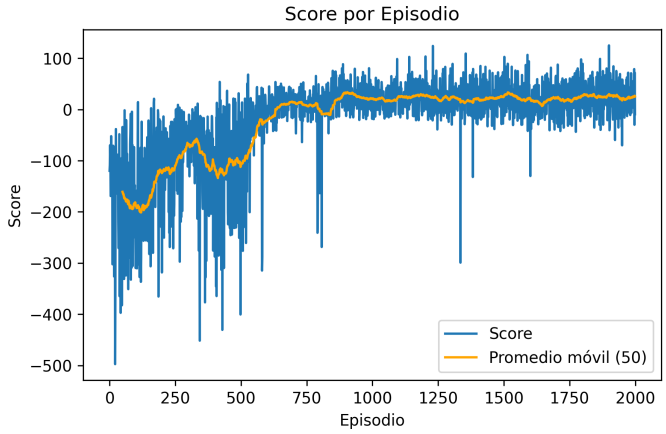

Fig. 27. Recompensa total con promedio móvil - Colab 5

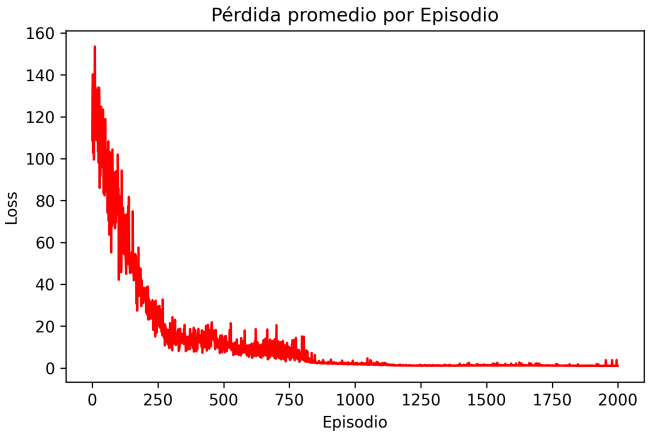

Fig. 28. Pérdida promedio por episodio - Colab 5

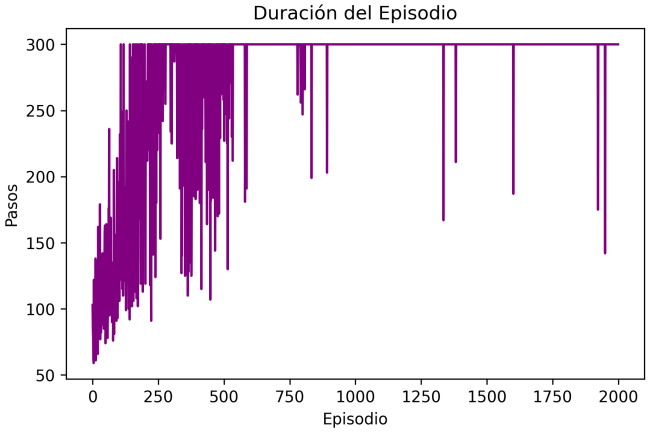

Fig. 29. Duración de los episodios - Colab 5

Se observa un aprendizaje extremadamente lento, con recompensas que apenas mejoran a lo largo del tiempo. Las pérdidas si se van reduciendo. La duración de los episodios fue artificialmente corta por el límite de pasos, lo que impidió desarrollar políticas más completas.

Durante la fase de prueba sin exploración, se obtuvo la siguiente tasa de acierto:

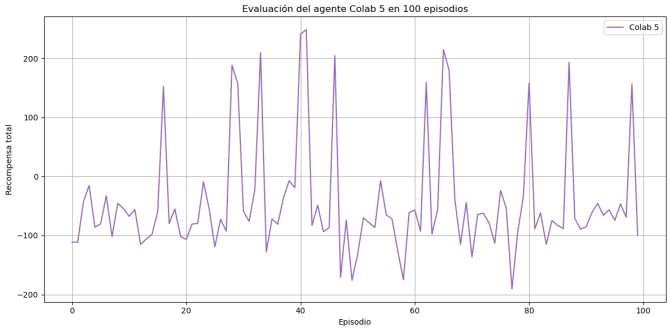

Fig. 30. Tasa de acierto del modelo ya entrenado - Colab 5

Este modelo alcanzó una tasa de acierto muy baja: solo **4.00%**, lo que evidencia que la política aprendida no incentivaba a completar la tarea correctamente, a excepción de casos particulares en los que funciona por no usar lo suficiente el motor principal y terminar ”aterrizando por error”.

F. Comparativa final

La siguiente tabla resume las configuraciones clave y los comportamientos observados en cada modelo. En un principio, el modelo Colab 2 se perfilaba como el mejor, pero fue finalmente superado por Colab 4.

Tras repetir entrenamientos con los mismos hiperparámetros, Colab 4 demostró mayor consistencia, mientras que Colab 2 era más impredecible: a veces obtenía mejores resultados, pero otras quedaba por debajo. Por ello, Colab 4 fue seleccionado como el modelo ganador por su estabilidad, eficiencia computacional y capacidad de generalización, incluso considerando la aleatoriedad inherente del entorno.

TABLA I
COMPARACIÓN DE HIPERPARÁMETROS USADOS EN LOS DISTINTOS ENTORNOS DE GOOGLE COLAB

Parámetro	Colab 1	Colab 2	Colab 3	Colab 4	Colab 5
replays_per_episode	1000	64	64	32	64
episodes	3000	1500	1500	1500	2000
hidden_size	256	128	128	256	64
learning_rate	0.001	0.0005	0.0005	0.0005	0.00005
batch_size	64	64	128	64	64
memory_size	10,000	100,000	100,000	100,000	100,000
target_network_update_freq	15	10	10	10	20
max_steps	500	500	500	500	300

Análisis de parámetros:

1) `replays_per_episode`: 1000 actualizaciones por episodio (Colab 1) tienden al sobreajuste. 32 (Colab 4) promueven mayor variabilidad y eficiencia, compensado con una red más compleja.
2) `episodes`: Con 1500 episodios bien aprovechados se logra convergencia. Más episodios no siempre implican mejor desempeño si la política no mejora.
3) `hidden_size`: 256 neuronas permiten maniobras complejas. Colab 4 aprovecha esto sin caer en sobreajuste, a diferencia de Colab 1. Tamaños pequeños (Colab 5) no son suficientemente configurables para tareas exigentes.
4) `learning_rate`: Tasa moderada (0.0005) proporciona aprendizaje estable. En Colab 5, una tasa muy baja impide progreso rápido y en Colab 1 una tasa más alta hace que no logre aprender.
5) `batch_size`: Un tamaño mayor (128 en Colab 3) suaviza el aprendizaje pero reduce agilidad. Colab 4 mantiene buen equilibrio.
6) `memory_size`: Un buffer pequeño (Colab 1) limita la diversidad de experiencias. Colab 4 utiliza un tamaño grande que mejora generalización.
7) `target_network_update_freq`: Actualizar cada 10 episodios (Colab 4) ofrece mayor estabilidad. Colab 5 lo hace con menor frecuencia, dificultando la adaptación.
8) `max_steps`: Valores bajos (Colab 5) impiden completar episodios. Esto favorece políticas que evitan el aterrizaje para mantener estabilidad en el aire.

Resumen del comportamiento observado en cada Colab:

- **Colab 1**: Mal aterrizaje, red costosa y sobreentrenada.
- **Colab 2**: Buen equilibrio entre exploración y estabilidad, pero más variante cuando se ejecuta varias veces.
- **Colab 3**: Flota en exceso y evita aterrizar, muchos episodios truncados.
- **Colab 4**: Gran control general, con una muy buena estabilidad y una tasa de aciertos muy alta incluso probandose repetidamente.
- **Colab 5**: Demasiado conservador, no desarrolla una política clara de descenso, simplemente intenta no chocar.

Resolución: Colab 4 logra el mejor balance general. Aprende rápido, es estable y eficiente. Su arquitectura y parámetros están mejor afinados al entorno, siendo este el modelo seleccionado en esta investigación.

IV. CONCLUSIONES

Este trabajo permitió comprobar la eficacia del algoritmo DQN para tareas de control continuo como el aterrizaje lunar simulado. A través de múltiples configuraciones experimentales, se evidenció que la elección de los hiperparámetros y la arquitectura de la red tiene un impacto crítico en el rendimiento del agente.

El modelo ”Colab 4 - The King Lander” se destacó por su consistencia, eficiencia y alta tasa de acierto (91%), superando ampliamente el objetivo inicial del 30%. Esto demuestra que con una configuración bien afinada es posible alcanzar políticas de control robustas incluso en entornos con alta variabilidad inicial.

Entre los principales desafíos encontrados estuvieron los problemas de compatibilidad con GPU, el tratamiento adecuado de los tensores y la correcta implementación de las redes y el algoritmo, pasando los conocimientos teóricos a código ejecutable. Aun así, el agente fue capaz de aprender comportamientos complejos como estabilización en el aire y aterrizajes suaves.

En adelante, sería interesante estudiar cómo evoluciona el rendimiento del agente bajo restricciones de energía o penalizaciones adicionales, simulando escenarios más realistas. También se podría investigar cómo adaptar este enfoque a entornos donde la información sensorial esté incompleta o sea ”ruidosa”.

Bibliografía

[1] Farama Foundation. *Gymnasium Documentation*. https://gymnasium.farama.org. Último acceso: junio de 2025.

[2] PyTorch Team. *PyTorch: Tensors and Dynamic neural networks in Python with strong GPU acceleration*. https://pytorch.org. Último acceso: junio de 2025.

[3] V. Mnih, K. Kavukcuoglu, D. Silver, A. Rusu, J. Veness, M. Bellemare, A. Graves, M. Riedmiller, A. Fidjeland, G. Ostrovski, et al. *Human-level control through deep reinforcement learning*. Nature, vol. 518, no. 7540, pp. 529–533, 2015. https://www.nature.com/articles/nature14236.

[4] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., online book, 2018. Disponible en: https://web.stanford.edu/class/psych209/Readings/SuttonBartoIPRLBook2ndEd.pdf.

[5] PyTorch, "Optimization tutorial," 2023. Disponible en: https://docs.pytorch.org/tutorials/beginner/basics/optimization_tutorial.html.

[6] Farama Foundation, "Lunar Lander environment," *Gymnasium*, 2023. Disponible en: https://gymnasium.farama.org/environments/box2d/lunar_lander/.

[7] S. Zolna, "Deep Q-Networks explained," *LessWrong*, 2019. Disponible en: https://www.lesswrong.com/posts/kyvCNgx9oAwJCuevo/deep-q-networks-explained.

[8] IBM, "Hyperparameter tuning," 2023. Disponible en: https://www.ibm.com/es-es/think/topics/hyperparameter-tuning.

[9] V. Mnih et al., "Human-level control through deep reinforcement learning," *Nature*, vol. 518, pp. 529–533, 2015. Disponible en: https://www.nature.com/articles/nature14236.

[10] OpenAI, "Spinning Up in Deep RL," 2023. Disponible en: https://spinningup.openai.com/en/latest/spinningup/rl_intro2.html.

[11] Hugging Face, "Large Language Models Course, Chapter 7," 2023. Disponible en: https://huggingface.co/learn/llm-course/chapter7/1.

[12] Pandas Development Team, "pandas.DataFrame.rolling," 2023. Disponible en: https://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.rolling.html.

[13] Lazy Programmer, "What is the replay buffer in DQN (Deep Q-Learning)?", 2019. Disponible en: https://lazyprogrammer.me/what-is-the-replay-buffer-in-dqn-deep-q-learning/.

[14] PyTorch, "torch.optim.Adam," 2023. Disponible en: https://docs.pytorch.org/docs/stable/generated/torch.optim.Adam.html#torch.optim.Adam.

[15] J. Code, "gym_solutions," GitHub repository, 2023. Disponible en: https://github.com/johnnycode8/gym_solutions.

[16] D. Silver, "Reinforcement Learning Introduction," YouTube video, 2019. Disponible en: https://www.youtube.com/watch?v=YAfS8-BXp8Q.

[17] H. V. Hasselt, "Deep Q-Networks Explained," YouTube video, 2020. Disponible en: https://www.youtube.com/watch?v=EgklwkyieOY.

[18] A. Ng, "Deep Reinforcement Learning Tutorial," YouTube video, 2018. Disponible en: https://www.youtube.com/watch?v=aircAruvnKk.

[19] S. Walters, "PyTorch Basics Tutorial," YouTube video, 2021. Disponible en: https://www.youtube.com/watch?v=EUrWGTCGzlA&t=7s.

[20] PyTorch, "Saving, Loading, and Running Models Tutorial," 2023. Disponible en: https://docs.pytorch.org/tutorials/beginner/basics/saveloadrun_tutorial.html.

[21] D. P. Kingma and J. Ba, "Adam: A Method for Stochastic Optimization," arXiv preprint arXiv:1412.6980, 2014. Disponible en: https://arxiv.org/abs/1412.6980.

Uso de inteligencia artificial generativa

Durante la elaboración de este trabajo se utilizó de forma puntual un modelo de inteligencia artificial generativa (ChatGPT) con el objetivo de resolver dudas concretas relacionadas con conceptos técnicos, redacción en LaTeX y formato bibliográfico.

En particular, se hicieron consultas como:

- "¿Cuál es la diferencia entre DQN y Q-Learning?"
- "¿Qué es mejor, PyTorch o Keras?"
- "¿Cómo optimizo un algoritmo con PyTorch?"
- "Explícame cómo hacer gráficas con `pyplot`".
- "¿Cómo cito correctamente artículos web en formato LaTeX?"

También se empleó el sistema para facilitar la escritura de ciertos fragmentos del informe, en especial al traducir contenido técnico a un lenguaje académico formal, y para generar pseudocódigo en estilo `algorithm2e` en LaTeX con nomenclatura coherente con el código real.

Cabe destacar que todas las respuestas fueron revisadas críticamente por los autores, adaptadas según el contexto del proyecto, y complementadas con comprensión propia y experimentación práctica. En ningún caso se utilizó la IA como sustituto del conocimiento necesario para la defensa del trabajo.